Fantasy Premier League Expected Points Predictor

Matias Wolden og Torstein Kristoffer Walle Thomassen, 26.10.2026

Lenke til streamlit web-app:
https://dat158-fplexpectedpointspredictor.streamlit.app/live-test

1: Beskrivelse av problemet

Fantasy Premier League (FPL) er det offisielle spillet til Premier League, og har over 10 millioner spillere. Hver manager har en tropp på 15 spillere og et budsjett. Før hver uke (Gameweek) velger man elleve spillere, som starter og en kaptein som får dobbel poengsum. Spillere får poeng for ulike ting som spilletid, mål, målgivende, redninger, clean sheets og bonuspoeng, i tillegg til dette kan de miste poeng for røde og gule kort samt hvis de bommer på en straffe.

Målet med prosjektet er å predikere hvor mange FPL-poeng hver spiller får i neste runde. Ut ifra prediksjonen kan en spiller velge startellever, kaptein og gjøre bytter ut ifra disse prediksjonene.

Hvorfor maskinlæring? Utfallet av en fotballkamp er svært usikkert, men poengsummen til en spiller henger sammen med målbare faktorer: formen til spilleren, spilletid, underliggende tall, hjemmekamp eller bortekamp, god eller dårlig motstander. Det er hundrevis av spillere å vurdere hver uke, og sammenhengende mellom faktorene er ikke enkle.

Hvordan løses problemet i dag? Det finnes noen AI- modeller der ute, men som er gjemt bak en betalingsmur som gjør det lite lukrativt for de fleste spillere. Mange spillere studerer tidligere kamper, ser på FPL sin egen Fixture diffuculty rating (FDR), leser skadenyheter, ser på fremtidige kamper og ser på videoer og innlegg på sosiale medier. Vår løsning er gratis, åpen og viser hvor treffsikre prediksjonene er.

Hvordan skal løsningen brukes? Løsningen er en webapp med fem sider. I sidepanelet velger brukeren sesong og runde:

- Spillere: En tabell med predikerte poeng for alle spillere i neste runde. Den viser motstander, hjemme/borte, FDR, pris, poengsnitt og minutter spilt i de siste fem kampene. Brukeren kan filtere på posisjon og søke på spillernes navn eller lag.
- Beste lag: Den beste startelleveren i en gyldig formasjon(man kan ikke ha 11 spisser f.eks), med forventede poeng, formasjon og samlet pris. For runder spilt vises også hvor mange poeng laget faktisk fikk, og hva det best mulige fikk.
- Mitt lag: Brukeren skriver inn sin FPL-kode til sitt lag og får forventede poeng for hver spiller i troppen. Den viser også det beste oppsettet bruken kunne valgt fra sin egen tropp, og hvor mange poeng som står på benken. Dermed kan spilleren se hvem som bør starte og hvem de burde velge som sin kaptein.

- Live-test: Før hver runde lagres prediksjonene, og når runden er spilt sammenlignes de med de faktiske poengene. Dette viser hvor godt modellene treffer på kamper de ikke har sett.
- Modeller: Sammenligner modellene vi har prøvd mot baselinen. Siden viser feilen på testsettet, både for alle spillere og bare for spillere som faktisk spilte. Den viser også feilen for runden, der hver modell bare er trent på kampene før runden. Til slutt viser den hva hver modell predikerer for hver spiller i neste runde. Brukeren kan derfor se hvilke modeller som man kan stole på og hvor mye de er uenige.
  Målgruppe og behov: Løsningen er laget for FPL-spillere som vil ta bedre avslutninger uten å bruke timer på å gjøre egen analyse hver uke eller å betale for lignende tjenester. Den gir objektivt utgangspunkt for valgene, og brukeren tar fortsatt den endelige avgjørelsen.

  Pipeline, Løsningen består av disse delene:
    1. Datainnhenting: historiske sesonger fra det åpne datasettet Vaastav/Fantasy-Premier-League, og sesongen som pågår fra det offisielle FPL-API-et
    2. Feature Engineering: Den samme koden brukes både til trening og i appen, slik at modellen alltid får features beregnet på samme måte.
    3. Trening og evaluering: Alle modellene testes og trenes, og lagres i en modellfil sammen med resultatene.
    4. Webappen: Henter ferske data, lager prediksjoner og viser dem

Metrikker

Vi måler hvor godt modellen treffer med Mean absolute error(MAE), altså hvor mange poeng prediksjonen i snitt bommer med per spiller per kamp. Vi valgte MAE fordi det er lett å forstå: En MAE på 1 betyr at modellen i snitt bommer med ett poeng. Med MSE ville enkeltkamper, med mange poeng som et hat trick, fått veldig stor vekt. Accuracy passer ikke, fordi vi predikerer et tall og ikke en kategori.

MAE måles både for alle spillere og bare for spillere som faktisk spilte. De fleste spillerne i FPL spiller ikke og får 0 poeng. Det er lett å predikere og gjør at feilen for alle spillere ser bedre ut enn den egentlig er. Feilen for spillerne som spilte, sier mer om hvor nyttig modellen er for managerne.

Vi tester modellen på to måter:

- Tidsbasert split: de flestes 80% av kampene brukes til trening og de nyeste 20% til test, slik at modellen aldri trenes på fremtidige kamper.
- Runde for runde: for hver runde i innværende sesong trenes modellen på kampene før runden. Det viser hvordan den ville prestert om den hadde vært i bruk hele sesongen.

Alle modellene sammenlignes med en baseline uten maskinlæring: spilleren får samme poengsum som snittet i de siste fem kampene. Det er omtrent slik mange managerne tenker når de velger spillere i form

2: DATA

Data og labels

Vi bruker tabelldata der hver rad er én spiller i én kamp i Premier League. Radene inneholder blant annet minutter spilt, forventede mål (xG), forventede målgivende (xA), bonuspoeng, posisjon, pris, om kampen var hjemme eller borte, og hvem motstanderen var.

Dataene kommer fra to steder. De to forrige sesongene hentes fra et åpent datasett på GitHub (vaastav/Fantasy-Premier-League), og årets sesong hentes fra FPL sitt eget API.

Til sammen har vi omtrent 58 000 rader, og det kommer rundt 660 nye for hver runde som spilles. For å se om dette er nok, trente vi modellen på ulike mengder data. Med 1 000 rader bommet den i snitt med 1,09 poeng, med 20 000 rader 1,01 og med alle 0,99. Forbedringen blir altså mindre og mindre, så vi mener vi har nok data. Vi tror det ville hjulpet mer å legge til ny informasjon, for eksempel skader, enn å samle flere rader.

Vi bruker supervised learning, siden vi har fasiten for hver kamp. Labelen er hvor mange FPL-poeng spilleren faktisk fikk. Siden vi skal forutsi et tall og ikke en kategori, er dette et regresjonsproblem. Labelen ligger allerede i datasettet, så vi trenger ikke merke noe selv.

Poengene regnes ut av FPL etter faste regler, så labelene er konsistente. Unntaket er at reglene endres litt fra sesong til sesong, og at poeng noen ganger rettes etter kampslutt. Derfor bruker vi bare runder som er helt ferdige.

Underveis i sesongen 26/27 legges hver ferdigspilte runde til i treningsdataene, slik at modellen hele tiden bruker den nyeste formen til spillerne.

Personvern og etikk

Dataene handler om virkelige personer, men det er offentlig statistikk om profesjonelle fotballspillere, og ingenting av det er sensitivt. Vi bruker ikke skadeopplysninger. Brukere kan slå opp sitt eget FPL-lag i appen, men det lagres ikke.

En mulig ulempe er at prediksjonene kan brukes til pengespill, noe modellen ikke er laget for. Vi viser også hvor mye modellen bommer, slik at ingen tror tallene er sikrere enn de er.

Hvordan dataene gis til modellen

En modell kan ikke bruke statistikk fra kampen den skal forutsi, for den kjenner vi ikke på forhånd. Vi lager derfor nye features som beskriver formen til spilleren: gjennomsnittet over de fem forrige kampene for åtte ulike statistikker. I tillegg bruker vi pris, hjemme/borte, FPLs

vanskelighetsgrad for kampen (FDR), hvor god motstanderen har vært i det siste, og posisjon. Posisjonen gjøres om til fire kolonner med 0 og 1 (one-hot encoding), siden modellene trenger tall. Til sammen blir det 17 features.

Det er viktig at formen bare regnes ut fra kamper som er spilt før den vi skal forutsi. Ellers ville modellen fått se deler av fasiten, noe som kalles datalekkasje. Av samme grunn deler vi dataene etter tid: de eldste 80 % brukes til trening og de nyeste 20 % til testing.

Av rensing har vi fjernet rader som ikke er spillere, sørget for at posisjonene heter det samme i begge kildene, og fjernet den første kampen til hver spiller i sesongen, siden det ikke finnes noen form å regne ut da. Nesten ingen verdier mangler, og de få som gjør det fylles inn med medianen.

Skalering betyr å gjøre om features slik at de har omtrent samme størrelse. Det trengs for lineær regresjon, men ikke for random forest og gradient boosting, som er bygget på beslutningstrær.

3: MODELLERING

Vi har sammenlignet tre modeller fra sckiit-learn: linear regression, random forest og gradient boosting. Alle får de samme 17 featurene. Som baseline brukte vi en enkel regel uten maskinlæring: spilleren får samme poengsum som snittet de siste fem kampene. Det tilsvarer omtrent hvordan mange managerne velger spillere i form.

Modellene ble trent på de eldste 80 % av kampene og testet på de nyeste 20 %. Alle modellene slo baselinen. For spillere som spilte, bommet de med rundt 1,95 poeng i snitt, mot 2,23 for baselinen, en forbedring på omtrent 12 %. For alle spillere var forbedringen mindre (0,99 mot 1,05), fordi over halvparten av spillerne ikke spiller og får 0 poeng, noe som er lett å predikere. Forskjellen mellom de tre modellene var svært liten. Vi testet også runde for runde i inneværende sesong, der modellene bare var trent på kampene før hver runde. Der slo alle modellene baselinen i hver runde, men sesongen har foreløpig bare fire runder.

Den lave forbedringen i MAE skjuler hvor nyttig modellen er. De 20 spillerne modellen rangerte høyest i hver runde, fikk i snitt 4,5 poeng, mot 3,7 for baselinens topp 20 og 2,9 for alle som spilte.

Med permutation importance fant vi at spilletid er den klart viktigste featuren, fulgt av form. Motstanderstyrke har en mindre effekt, mens hjemme/borte og posisjon betyr nesten ingenting.

Feilanalysen viser at modellen treffer godt på spillere med få poeng, men bommer kraftig på de store poengsummene. Den predikerer aldri over 9 poeng, selv om enkelte spillere får over 20. Mål og bonuspoeng er sjeldne og tilfeldige, så modellen holder seg nær snittet. Feilen er størst for forsvarere og keepere, der det å holde nullen er vanskelig å forutsi.

For å forbedre modellen vil vi ta med skadestatus fra FPL-API-et, siden spilletid er det viktigste og modellen i dag ikke vet om en spiller er skadet. Vi kan også prøve en todelt modell som først predikerer om spilleren spiller, og deretter hvor mange poeng han får.

4: DEPLOYMENT

Hvordan modellene er satt i drift: Modellene trenes lokalt med “python -m src.train” og lagres i én fil (model.joblib) i GitHub-repoet. Appen er laget i Streamlit og ligger på Streamlit Community Cloud: https://dat158-fplexpectedpointspredictor.streamlit.app/. Den er koblet til repoet, så nettsiden oppdateres automatisk hver gang vi pusher til “main”.

Hvordan prediksjonene brukes: Appen henter ferske data fra FPL hver time og viser hvor mange poeng hver spiller forventes å få i neste runde. Brukeren kan se alle spillerne rangert, det beste laget for runden, og forventede poeng og kapteinsanbefaling for sitt eget FPL-lag. Prediksjonene er ment som støtte når man velger lag, ikke som en fasit.

Monitorering: Vi overvåker modellene på to måter. På siden «Modeller» ser vi feilen på testsettet og per runde. På siden «Live-test» lagres prediksjonene før hver runde spilles, og sammenlignes med de faktiske poengene etterpå. Lagringen gjøres av en GitHub Actions-jobb som kjører hver morgen.Så langt er runde 6 og 7 spilt og evaluert. For alle spillere bommet modellene med 1,17–1,19 poeng i snitt, mot 1,23 for baselinen. Det er noe høyere enn på testsettet (0,99), men modellene slo baselinen i begge rundene. For de 20 faste spillerne, de fem med flest minutter i hver posisjon, var forskjellen større: modellene bommet med 2,1–2,3 poeng mot 3,2 for baselinen. Med bare to runder er tallene usikre, men de tyder på at modellen også fungerer på kamper den ikke har sett, og at gevinsten er størst for spillerne managerne faktisk vurderer.

Vedlikehold: Dette må gjøres manuelt i dag:

- trene modellene på nytt når det har kommet nye runder
- oppdatere hvilken sesong som er inneværende når en ny sesong starter
- følge med på om FPL endrer API-et sitt, siden appen da kan slutte å virke

Planer for forbedring:

- trene modellene på nytt automatisk etter hver runde
- legge til skader og forventet spilletid, som er det modellen mangler mest
- ta hensyn til budsjett og maks tre spillere per klubb i «Beste lag»

5: KONKLUSJON

Fotball er vanskelig å forutsi. Ett mål, straffe eller et rødt kort kan avgjøre en kamp. Der de fleste FPL - poeng komer fra slike sjeldne hendelser. Modellen vår bommer derfor fortsatt med rundt to poeng for spillere som spiller, og den forutser aldri de store poengsummene. Likevel slo alle modellene baselinen, både på testsettet og i live-testen, og de er klart bedre til å finne spillerne som får mest poeng. Prediksjonene blir aldri en fasit, men de gir bedre utgangspunkt enn bare å se på formen for de siste kampene.

REFERANSER

- vaastav. Fantasy-Premier-League (datasett). https://github.com/vaastav/Fantasy-Premier-League
- Fantasy Premier League, offisielt API. https://fantasy.premierleague.com/api/
- Fantasy Premier League, poengregler. https://fantasy.premierleague.com/help/rules
- Pedregosa m.fl. (2011). Scikit-learn: Machine Learning in Python. JMLR 12, s. 2825–2830.
- scikit-learn-dokumentasjon: HistGradientBoostingRegressor. https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.HistGradientBoostingRegressor.html
- Streamlit-dokumentasjon. https://docs.streamlit.io